요구사항 정의서

OCR 기반 개인정보 비식별화·검수 플랫폼

문서 버전	v0.1
작성 목적	프로젝트 범위와 기능/비기능 요구사항을 정의하여 개발, 테스트, 운영, 발표 자료 작성의 기준으로 활용
대상 독자	팀원, 지도교수/멘토, 포트폴리오 검토자
프로젝트 성격	OCR·개인정보보호·운영 콘솔·비동기 처리·검수 워크플로우를 포함한 솔루션형 프로젝트

1. 프로젝트 개요

1.1 프로젝트 배경

공공기관, 기업, 교육기관 등에서는 이미지, 스캔 문서, PDF 형태의 문서 내 개인정보를 외부 제출, 내부 공유, 보관 전에 비식별화해야 하는 경우가 많다. 그러나 수작업 마스킹은 시간이 오래 걸리고 누락·오탐 가능성이 높으며, 작업 이력 관리가 어렵다.

본 프로젝트는 OCR 을 통해 문서 내 텍스트를 추출하고, 주민등록번호·전화번호·이메일·주소 등 개인정보를 탐지한 뒤 자동 마스킹을 수행하며, 운영자가 웹 콘솔에서 검수·정책 관리·처리 이력 확인을 할 수 있는 개인정보 비식별화 운영 플랫폼을 구축하는 것을 목표로 한다.

1.2 프로젝트 목표

- 이미지/PDF 문서에서 OCR 기반 텍스트 추출 기능 제공
- 개인정보 자동 탐지 및 마스킹 기능 제공
- 검수자가 웹 콘솔에서 결과를 수정·확정할 수 있는 검수 기능 제공
- 관리자 권한 기반 정책 관리 기능 제공
- 처리 이력, 감사 로그, 실패 작업 재처리 기능 제공
- 비동기 처리 구조 및 운영 가능한 배포 구조 설계

1.3 기대 효과

- 문서 내 개인정보 마스킹 자동화로 반복 업무 감소
- 사람 검수 기반 보완으로 오탐·누락 리스크 감소
- 정책 변경, 처리 이력, 감사 로그를 통한 관리 효율 향상
- 보안 솔루션형 웹 플랫폼과 운영 인프라를 함께 보여주는 포트폴리오 확보

2. 프로젝트 범위

2.1 포함 범위

- 이미지/PDF 파일 업로드
- OCR 텍스트 추출
- 개인정보 탐지
- 자동 마스킹
- 검수 및 수정
- 정책 관리
- 처리 이력 조회
- 실패 건 재처리
- 사용자 권한 분리
- 감사 로그 기록

2.2 제외 범위

- 모바일 앱 제공
- 실시간 공동 편집
- 다국어 OCR 최적화
- 고정밀 AI 학습/재학습 파이프라인
- 다중 고객사(멀티테넌시) 지원
- 전자결재 시스템 연동
- 외부 기관 API 자동 제출

3. 이해관계자 및 사용자

3.1 이해관계자

- 시스템 관리자: 정책, 사용자, 전체 운영 관리
- 검수자: OCR/마스킹 결과 검토 및 수정
- 조회자: 처리 결과 및 이력 조회
- 개발/운영자: 시스템 배포, 장애 대응, 성능 개선

3.2 사용자 역할

역할	권한 및 책임
관리자(Admin)	사용자 계정 및 권한 관리, 탐지/마스킹 정책 생성·수정·비활성화, 전체 처리 현황 및 감사 로그 조회, 실패 작업 재처리
검수자(Reviewer)	처리 완료 문서 검수, 탐지 결과 수정·삭제·추가, 최종 결과 확정·반려
조회자(Viewer)	문서 처리 현황 조회, 검수 완료 결과 열람, 다운로드 이력 확인

4. 시스템 개요

4.1 시스템 구성

- Frontend: 웹 기반 운영 콘솔
- Backend API: 업로드, 조회, 검수, 정책 관리 API
- Worker: OCR 및 개인정보 탐지/마스킹 비동기 처리
- Queue: 처리 작업 대기열
- Database: 문서 메타데이터, 결과, 정책, 검수 이력, 감사 로그 저장
- Object Storage: 원본 문서 및 결과 파일 저장
- Monitoring: 로그, 메트릭, 에러 추적

4.2 처리 흐름

1. 사용자가 문서를 업로드한다.
2. 시스템은 원본 파일을 저장하고 처리 작업을 생성한다.
3. Worker 가 OCR 을 수행한다.
4. 시스템은 추출된 텍스트에서 개인정보를 탐지한다.
5. 시스템은 정책에 따라 마스킹 결과를 생성한다.
6. 처리 결과를 DB 에 저장한다.
7. 검수자가 웹 콘솔에서 결과를 검토/수정한다.
8. 검수 완료 후 최종 결과를 저장·조회·다운로드할 수 있다.

5. 기능 요구사항

5.1 사용자 인증 및 권한 관리

FR-01 로그인 기능

- 사용자는 아이디/비밀번호를 통해 로그인할 수 있어야 한다.
- 로그인 성공 시 사용자 권한에 따라 접근 가능한 메뉴가 달라야 한다.

FR-02 권한 기반 접근 제어

- 시스템은 관리자, 검수자, 조회자 역할을 구분해야 한다.
- 역할별 메뉴 및 기능 접근 권한을 제한해야 한다.

FR-03 세션 관리

- 사용자의 로그인 세션은 일정 시간 무작동 시 만료되어야 한다.
- 비정상 접근 시 재인증을 요구해야 한다.

5.2 문서 업로드 및 관리

FR-04 문서 업로드

- 사용자는 이미지 파일 및 PDF 파일을 업로드할 수 있어야 한다.
- 시스템은 업로드 시 파일명, 업로드 시간, 업로드 사용자, 파일 형식, 파일 크기를 저장해야 한다.

FR-05 업로드 유효성 검증

- 시스템은 허용된 파일 형식만 업로드 가능해야 한다.

- 허용 크기를 초과한 파일은 업로드를 제한해야 한다.

FR-06 문서 상태 관리

- 문서 상태는 최소 Uploaded, Processing, Completed, Failed, Reviewed 값을 가져야 한다.

FR-07 문서 목록 조회

- 사용자는 문서 목록을 조회할 수 있어야 한다.
- 상태, 업로드 일시, 업로더, 파일명 기준으로 검색/필터링할 수 있어야 한다.

5.3 OCR 처리

FR-08 OCR 실행

- 시스템은 업로드된 문서에 대해 OCR 을 수행해야 한다.
- OCR 결과는 문서별, 페이지별로 저장되어야 한다.

FR-09 OCR 결과 저장

- 추출된 텍스트는 원문 기준으로 저장되어야 한다.
- 페이지 번호, 위치 정보(bounding box), 신뢰도 점수를 저장할 수 있어야 한다.

FR-10 비동기 처리

- OCR 및 후속 처리는 비동기 작업으로 수행되어야 한다.
- 사용자는 업로드 후 즉시 처리 대기/진행 상태를 확인할 수 있어야 한다.

5.4 개인정보 탐지 및 마스킹

FR-11 개인정보 탐지

- 시스템은 OCR 결과 텍스트에서 개인정보를 탐지해야 한다.
- 최소 탐지 대상은 주민등록번호, 전화번호, 이메일, 주소, 계좌번호 유사 패턴을 포함해야 한다.

FR-12 탐지 결과 구조화

- 탐지 결과는 유형, 원문 값, 위치, 탐지 방식, 신뢰도 등의 형태로 저장되어야 한다.

FR-13 자동 마스킹

- 시스템은 탐지된 개인정보에 대해 정책 기반 자동 마스킹을 수행해야 한다.
- 유형별 마스킹 규칙은 다르게 설정 가능해야 한다.

FR-14 마스킹 결과 저장

- 시스템은 원본 OCR 결과와 별도로 마스킹 결과를 저장해야 한다.
- 최종 결과와 자동 처리 결과를 구분할 수 있어야 한다.

5.5 검수 기능

FR-15 검수 화면 제공

- 검수자는 문서 원본, OCR 텍스트, 탐지된 개인정보 목록, 마스킹 결과를 한 화면에서 확인할 수 있어야 한다.

FR-16 검수 수정 기능

- 검수자는 탐지 결과를 수정/삭제/추가할 수 있어야 한다.
- 검수자는 마스킹 결과를 수동 수정할 수 있어야 한다.

FR-17 검수 상태 변경

- 검수자는 문서를 확정 또는 반려할 수 있어야 한다.
- 반려 시 반려 사유를 남길 수 있어야 한다.

FR-18 검수 이력 저장

- 검수 수행자, 검수 일시, 수정 여부, 메모를 저장해야 한다.

5.6 정책 관리

FR-19 탐지 정책 관리

- 관리자는 개인정보 탐지 대상 유형을 활성화/비활성화할 수 있어야 한다.
- 유형별 탐지 규칙을 수정할 수 있어야 한다.

FR-20 마스킹 정책 관리

- 관리자는 유형별 마스킹 방식(부분 마스킹, 전체 마스킹 등)을 설정할 수 있어야 한다.

FR-21 정책 버전 관리

- 정책 변경 시 변경 이력을 저장해야 한다.
- 새 정책은 신규 처리 문서에만 적용되도록 관리할 수 있어야 한다.

5.7 이력 및 감사 로그

FR-22 처리 이력 조회

- 사용자는 문서 단위 처리 이력을 조회할 수 있어야 한다.

- 업로드, 처리 시작, 처리 완료, 실패, 재처리, 검수 완료 이력을 확인할 수 있어야 한다.

FR-23 감사 로그 기록

- 시스템은 로그인, 조회, 수정, 검수, 다운로드, 정책 변경 등의 행위를 로그로 남겨야 한다.

FR-24 다운로드 이력 관리

- 시스템은 결과 파일 다운로드 이력을 저장해야 한다.

5.8 실패 처리 및 재처리

FR-25 실패 사유 저장

- 처리 실패 시 실패 단계와 에러 메시지를 저장해야 한다.

FR-26 재처리 기능

- 관리자는 실패한 문서를 재처리할 수 있어야 한다.
- 재처리 이력은 별도로 기록되어야 한다.

5.9 대시보드 및 통계

FR-27 운영 대시보드

- 시스템은 전체 문서 처리 건수, 실패 건수, 검수 대기 건수, 개인정보 유형별 탐지 건수, 일별 처리 추이를 시각적으로 제공해야 한다.

FR-28 검색 및 필터

- 문서 및 이력 조회 시 날짜, 상태, 유형, 사용자 기준 필터를 제공해야 한다.

6. 비기능 요구사항

6.1 성능 요구사항

NFR-01 처리 응답성

- 사용자는 업로드 요청 후 즉시 접수 결과를 확인할 수 있어야 한다.
- 업로드 요청은 동기 처리로 장시간 블로킹되지 않아야 한다.

NFR-02 대량 처리

- 시스템은 다수의 문서가 동시에 업로드되는 상황에서도 큐 기반으로 안정적으로 처리되어야 한다.

NFR-03 조회 성능

- 문서 목록 및 이력 조회 화면은 페이지네이션을 지원해야 하며, 과도한 조회 지연이 발생하지 않아야 한다.

6.2 가용성 및 복구 요구사항

NFR-04 장애 격리

- OCR 처리 실패가 전체 웹 서비스 중단으로 이어지지 않아야 한다.

NFR-05 재처리 가능성

- 일시적 오류 발생 시 작업 재시도 또는 수동 재처리가 가능해야 한다.

NFR-06 데이터 보존

- 원본 문서, 처리 결과, 검수 결과, 감사 로그는 별도로 보존되어야 한다.

6.3 보안 요구사항

NFR-07 접근 통제

- 권한이 없는 사용자는 문서 원본, OCR 결과, 검수 결과에 접근할 수 없어야 한다.

NFR-08 민감정보 보호

- 개인정보가 포함된 데이터는 저장 및 전송 과정에서 보호되어야 한다.
- 운영 환경에서는 HTTPS 등 암호화 통신을 적용해야 한다.

NFR-09 감사 가능성

- 주요 사용자 행위는 추적 가능해야 하며, 로그 위변조 방지 방안을 고려해야 한다.

6.4 운영 및 유지보수 요구사항

NFR-10 로그/모니터링

- 시스템 상태, 에러, 처리량, 실패율, 큐 적체 여부를 확인할 수 있어야 한다.

NFR-11 설정 변경 용이성

- 정책, 허용 파일 크기, 저장 경로, 처리 옵션 등 주요 설정은 코드 수정 없이 변경 가능해야 한다.

NFR-12 확장성

- OCR Worker 는 처리량 증가 시 수평 확장이 가능해야 한다.

7. 데이터 요구사항

7.1 Document

- 문서 ID
- 원본 파일명
- 파일 경로
- 파일 형식
- 파일 크기
- 업로드 사용자
- 업로드 시각
- 처리 상태

7.2 OCRResult

- 결과 ID
- 문서 ID
- 페이지 번호
- 추출 텍스트
- 위치 정보
- 신뢰도

7.3 PIIItem

- 항목 ID
- 문서 ID
- 개인정보 유형
- 원문 값
- 마스킹 값
- 탐지 위치
- 탐지 방식
- 신뢰도

7.4 Review

- 검수 ID
- 문서 ID
- 검수자
- 검수 상태
- 수정 내용
- 메모
- 검수 시각

7.5 Policy

- 정책 ID
- 정책명
- 적용 대상 유형
- 마스킹 규칙
- 활성화 여부
- 버전
- 생성/수정 일시

7.6 AuditLog

- 로그 ID
- 사용자 ID
- 행위 유형
- 대상 ID
- 행위 시각
- 상세 내용

8. 화면 요구사항

8.1 로그인 화면

- 사용자 로그인

- 인증 실패 메시지 표시

8.2 대시보드

- 처리 건수, 실패 건수, 검수 대기 건수 표시
- 유형별 탐지 건수 차트 표시

8.3 문서 목록 화면

- 문서 리스트
- 상태/날짜/업로더 필터
- 문서 상세 이동
- 재처리 버튼

8.4 문서 상세/검수 화면

- 원본 미리보기
- OCR 추출 텍스트 표시
- 탐지 결과 리스트
- 자동 마스킹 결과 확인
- 수동 수정/확정/반려

8.5 정책 관리 화면

- 탐지 정책 목록
- 마스킹 규칙 수정
- 정책 활성화/비활성화

8.6 이력/감사 로그 화면

- 사용자 행위 이력
- 정책 변경 이력
- 다운로드 이력

9. 인터페이스 요구사항

9.1 사용자 인터페이스

- 웹 브라우저 기반으로 동작해야 한다.
- 관리자 콘솔은 데스크톱 환경 사용을 기본으로 한다.

9.2 시스템 인터페이스

- Frontend 는 Backend API 와 REST 방식으로 통신한다.
- Backend 는 Queue 를 통해 Worker 에게 작업을 전달한다.
- Backend/Worker 는 DB 및 Object Storage 와 연동한다.

10. 제약사항

- OCR 정확도는 문서 품질, 글꼴, 해상도, 스캔 상태에 따라 달라질 수 있다.
- 주소, 이름 등 일부 개인정보는 정규식 기반 탐지 정확도에 한계가 있을 수 있다.
- 본 프로젝트는 상용 수준 완성도를 목표로 하지 않고, MVP 수준의 실증 가능한 솔루션 구현을 목표로 한다.
- 초기 버전은 한국어 문서 중심으로 설계한다.

11. 테스트 및 검수 기준

11.1 기능 테스트 기준

- 이미지/PDF 업로드가 정상 동작해야 한다.
- OCR 결과가 DB 에 저장되어야 한다.
- 개인정보 탐지 및 자동 마스킹이 수행되어야 한다.
- 검수자가 결과를 수정 후 확정할 수 있어야 한다.
- 정책 변경 후 신규 문서 처리에 반영되어야 한다.
- 실패 건 재처리가 가능해야 한다.

11.2 비기능 테스트 기준

- 동시 업로드 시 큐 적체 및 처리 상태가 정상적으로 표시되어야 한다.
- Worker 중단 시 웹 서비스는 정상 접근 가능해야 한다.

- 주요 사용자 행위가 감사 로그로 남아야 한다.

12. MVP 기준

12.1 MVP 필수 기능

- 로그인
- 문서 업로드
- OCR 추출
- 전화번호/이메일/주민번호 탐지
- 자동 마스킹
- 문서 목록 조회
- 검수 화면
- 확정/반려
- 처리 이력
- 실패 재처리

12.2 2 차 확장 기능

- 주소/계좌번호 정교화
- PDF 페이지별 마스킹 렌더링
- 정책 버전 비교
- 알림 기능
- 외부 저장소 연동
- Kubernetes 기반 배포

13. 성공 기준

- 업로드부터 OCR, 탐지, 마스킹, 검수, 결과 저장까지 전체 흐름이 동작한다.
- 관리자와 검수자 권한 분리가 동작한다.
- 처리 실패 시 원인 확인 및 재처리가 가능하다.
- 정책과 감사 로그를 통해 운영형 솔루션의 형태를 갖춘다.

- 성능 개선 또는 구조 개선 사례를 최소 1 건 이상 정리할 수 있다.
- 포트폴리오에서 “개인정보 보호 솔루션 개발”과 “운영 가능한 인프라 설계”를 함께 설명할 수 있다.